

Base de Datos Sisbén IV

Documentación Técnica

Estructura del CSV, proceso ETL y columnas calculadas

Archivo fuente analizado

BD marzo 16 2026.csv

Tamaño: 1.97 GB

Separador: punto y coma (;)

Encoding: UTF-8 con BOM

Columnas: 150

Registros: $\approx$ 4-5 millones (archivo de marzo 2026)

Rango total del Parquet maestro: $\approx$ 25 millones de filas

Valentina Vanegas Aristizabal

Coordinación Departamental Sisbén IV

Dirección de Información y Estudios Económicos

Gobernación de Antioquia

Medellín, abril de 2026

Índice

1. Contexto y fuente de datos	3
2. Estructura del CSV: las 150 columnas	3
2.1. Bloque 1: Identificación geográfica (columnas 000–005)	3
2.2. Bloque 2: Metadatos del registro (columnas 006, 147–149)	4
2.3. Bloque 3: Vivienda — tipo y materiales (columnas 007–009)	4
2.4. Bloque 4: Servicios públicos (columnas 010–016)	5
2.5. Bloque 5: Hogar — espacio, saneamiento y agua (col. 017–033)	5
2.6. Bloque 6: Equipamiento y gastos del hogar (col. 034–062)	6
2.7. Bloque 7: Eventos de riesgo (columnas 064–075)	7
2.8. Bloque 8: Persona — características individuales (col. 076–129)	7
2.9. Bloque 9: Indicadores IPM y score (columnas 130–145)	9
3. Proceso ETL: de CSV a Parquet maestro	10
3.1. Versión 1: ETL DuckDB inicial (<code>etl_sisben.py</code>)	10
3.2. Versión 2: ETL DuckDB con metadatos (<code>etl_sisben_v2.py</code>)	10
3.3. Patch: corrección de regex (<code>patch_parquet.py</code>)	11
3.4. Versión 3 definitiva: Python chunk mode (<code>etl_sisben_definitivo.py</code>)	11
3.5. Script complementario: ETL de población DANE (<code>etl_poblacion_cobertura.py</code>)	11
4. Las 24 columnas calculadas: lógica exacta	12
4.1. Grupo A: Clasificación Sisbén	12
4.1.1. <code>orden_clasificacion</code> (Int64)	12
4.2. Grupo B: Tipo y materiales de vivienda	12
4.2.1. <code>Tipo_Vivienda_txt</code> (String)	12
4.2.2. <code>Material de las Paredes</code> (String)	12
4.2.3. <code>Material del Piso</code> (String)	13
4.2.4. <code>Orden_Paredes</code> (Int64)	13
4.2.5. <code>Tipo_Ocupacion_txt</code> (String)	13
4.3. Grupo C: Servicios públicos	13
4.3.1. <code>Energia_txt / Acueducto_txt / Alcantarillado_txt / Gas_txt / Re-coleccion_txt</code> (String)	13
4.3.2. <code>Clase_txt / Zona</code> (String)	13
4.3.3. <code>Sanitario_txt</code> (String)	13
4.4. Grupo D: Calidad y hacinamiento de vivienda	13
4.4.1. <code>Privaciones_Vivienda</code> (Int64)	13
4.4.2. <code>Nivel_Calidad_Vivienda</code> (String)	13
4.4.3. <code>Personas_por_Cuarto</code> (Float64)	14
4.4.4. <code>Cat_Hacinamiento</code> (String)	14
4.5. Grupo E: Persona y jefatura del hogar	14
4.5.1. <code>Es_Jefe</code> (Int64)	14
4.5.2. <code>Sexo_Jefe</code> (Int64)	14
4.5.3. <code>Sexo_Jefe_Label</code> (String)	14
4.6. Grupo F: Edad	14
4.6.1. <code>Rango_Edad</code> (String)	14
4.6.2. <code>Orden_Edad</code> (Int64)	14

4.7. Grupo G: Salud	14
4.7.1. Regimen_Salud_Limpio (String)	14
5. Normalización de tipos de datos	15
6. Eficiencia lograda: comparativa cuantitativa	15
7. Propuesta de transición a SQL	16
8. Glosario de términos clave	16

Contexto y fuente de datos

El Departamento Nacional de Planeación (DNP) genera y distribuye periódicamente cortes actualizados de la base Sisbén IV a cada Coordinación Departamental en formato CSV. Para el departamento de Antioquia, la Coordinación recibe un archivo por corte con todos los registros de personas encuestadas en los 125 municipios.

Archivo fuente — corte de marzo 2026

Nombre:	BD marzo 16 2026.csv
Ruta original:	D:\VVANEGASA\Downloads\
Tamaño en disco:	1.971.399.330 bytes (1,97 GB)
Separador:	punto y coma (;)
Codificación:	UTF-8 con BOM (utf-8-sig)
Columnas en bruto:	150
Tipos en bruto:	Todo como texto (string) — sin tipos numéricos nativos

La base recibe el nombre de “anonimizada” porque no incluye el número de cédula ni nombres propios de las personas. La identificación del registro se hace mediante `cod_dpto`, `cod_mpio` y los identificadores de hogar y persona dentro de ese municipio.

Cobertura temporal en el Parquet maestro

El Parquet maestro consolida **6 cortes anuales** del DNP (2021–2026), cada uno en archivos CSV separados, más el presente corte de marzo 2026 que se usa como referencia de estructura. El total de registros consolidados alcanza aproximadamente **25 millones de filas**.

Estructura del CSV: las 150 columnas

Las columnas se agrupan en ocho bloques temáticos, reflejando la estructura jerárquica de la encuesta Sisbén IV: **vivienda** → **hogar** → **persona**.

Unidad de fila: cada fila representa **una persona**. Los atributos de su vivienda y su hogar se repiten en cada fila de los miembros del mismo hogar. La columna `tip_parentesco = 1` identifica al jefe o jefa del hogar.

Bloque 1: Identificación geográfica (columnas 000–005)

Col	Nombre	Tipo bruto	Descripción
000	<code>cod_dpto</code>	String	Código DANE del departamento. Antioquia = 05.
001	<code>cod_mpio</code>	String	Código DANE del municipio (5 dígitos). Ej: 05001 = Medellín.
002	<code>Cod_clase</code>	Entero	Clase de la unidad territorial: 1=Cabecera urbana, 2=Centro poblado, 3=Rural disperso.

Col	Nombre	Tipo bruto	Descripción
003	NOM_CORREGIMIENTO	String	Nombre del corregimiento; SIN CORREGIMIENTO si aplica.
004	NOM_VEREDA	String	Nombre de la vereda; SIN VEREDA en zona urbana.
005	NOM_BARRIO	String	Nombre del barrio en zona urbana.

Bloque 2: Metadatos del registro (columnas 006, 147–149)

Col	Nombre	Tipo bruto	Descripción
006	Fec_digitacion	String (fecha)	Fecha y hora de digitación del registro. Formato: AAAA-MM-DD HH:MM:SS.mmm.
146	Clasificacion	String	Clasificación Sisbén IV con letra y número: A1–A5, B1–B7, C1–C18, D1–D21. La letra indica el grupo (A = más vulnerable).
147	Edad	Entero	Edad en años cumplidos al momento de la encuesta.
148	marca	Entero (0/1)	Marcador de estado especial del registro. 0=registro estándar.
149	estado	Entero (0/1)	Estado del registro en el sistema. 0=vigente.

Bloque 3: Vivienda — tipo y materiales (columnas 007–009)

Col	Nombre	Tipo / Cate- gorías	Descripción
007	tip_vivienda	1–5 (categórico)	1=Casa 2=Apartamento 3=Cuarto 4=Otro tipo 5=Vivienda indígena
008	tip_mat_paredes	0–7 (categórico)	0=Sin paredes 1=Bloque/ladrillo/piedra/madera pulida 2=Tapia pisada o adobe 3=Bahareque 4=Material prefabricado 5=Madera burda/tabla/ta- blón 6=Guadua/caña/vegetal 7=Zinc/tela/lona/cartón/desechos

Col	Nombre	Tipo / Cate- gorías	Descripción
009	<code>tip_mat_pisos</code>	1–6 (categórico)	1=Alfombra/mármol/parqué/madera pulida 2=Baldosa/vinilo/tableta/ladrillo 3=Cemento/gravilla 4=Madera burda/tabla/-tablón 5=Tierra o arena 6=Otro

Bloque 4: Servicios públicos (columnas 010–016)

Todos los indicadores `ind_tiene_*` usan la codificación binaria: 1=Sí tiene, 2=No tiene.

Col	Nombre	Descripción
010	<code>ind_tiene_energia</code>	Indicador binario de acceso a energía eléctrica (1=Sí / 2=No).
011	<code>tip_estrato_energia</code>	Estrato de facturación eléctrica: 1–6.
012	<code>ind_tiene_alcantarillado</code>	Indicador binario de acceso a alcantarillado.
013	<code>ind_tiene_gas</code>	Indicador binario de acceso a gas domiciliario.
014	<code>ind_tiene_recoleccion</code>	Indicador binario de servicio de recolección de basuras.
015	<code>ind_tiene_acueducto</code>	Indicador binario de acceso a acueducto.
016	<code>tip_estrato_acueducto</code>	Estrato del acueducto: 1–6.

Bloque 5: Hogar — espacio, saneamiento y agua (col. 017–033)

Col	Nombre	Tipo	Descripción
017	<code>num_cuartos_vivienda</code>	Entero	Número total de cuartos en la vivienda.
018	<code>num_hogares_vivienda</code>	Entero	Número de hogares que comparten la vivienda.
019	<code>ide_hogar</code>	Entero	Identificador del hogar dentro de la vivienda (1 si es único).
020	<code>tip_ocupa_vivienda</code>	1–5 (cat.)	1=Arriendo 2=Propia pagando 3=Propia pagada 4=Con permiso 5=Posesión sin título.
021	<code>num_cuartos_exclusivos</code>	Entero	Cuartos de uso exclusivo del hogar.
022	<code>num_cuartos_dormir</code>	Entero	Cuartos usados para dormir.
023	<code>num_cuartos_unicos_dormir</code>	Entero	Cuartos usados únicamente para dormir.

Col	Nombre	Tipo	Descripción
024	<code>tip_sanitario</code>	1-5 (cat.)	1=Alcantarillado 2=Pozo séptico 3=Sin conexión 4=Letrina/bajamar 5=No tiene.
025	<code>tip_ubi_sanitario</code>	Categorico	Ubicación del sanitario (dentro/fuera de la vivienda).
026	<code>tip_uso_sanitario</code>	Categorico	Uso exclusivo o compartido del sanitario.
027	<code>tip_origen_agua</code>	Categorico	Origen del agua: acueducto, pozo, lluvia, etc.
028	<code>ind_agua_llega_7dias</code>	Binario	Indica si el agua llega los 7 días de la semana.
029	<code>num_dias_llega</code>	Entero	Días a la semana que llega el agua (9=todos).
030	<code>ind_agua_llega_24horas</code>	Binario	Indica si el agua llega las 24 horas.
031	<code>num_horas_llega</code>	Entero	Horas/día que llega el agua (99=todo el día).
032	<code>tip_uso_agua_beber</code>	Categorico	Fuente de agua para consumo humano.
033	<code>tip_elimina_basura</code>	Categorico	Forma de eliminación de basura.

Bloque 6: Equipamiento y gastos del hogar (col. 034–062)

Los indicadores `ind_tiene_*` de equipamiento usan 1=Sí, 2=No. Los pares `ind_gasto_*` / `vlr_gasto_*` indican si el hogar tiene ese gasto y el valor en pesos colombianos.

Col	Nombre	Tipo	Descripción
034	<code>ind_tiene_cocina</code>	Binario	Dispone de espacio para cocinar.
035	<code>tip_prepara_alimentos</code>	Categorico	Lugar donde se preparan los alimentos.
036	<code>tip_uso_cocina</code>	Categorico	Uso exclusivo o compartido de la cocina.
037	<code>tip_energia_cocina</code>	Categorico	Tipo de energía para cocinar (gas, leña, electricidad, etc.).
038	<code>ind_tiene_nevera</code>	Binario (1/2)	Tiene nevera.
039	<code>ind_tiene_lavadora</code>	Binario (1/2)	Tiene lavadora.
040	<code>ind_tiene_pc</code>	Binario (1/2)	Tiene computador.
041	<code>ind_tiene_internet</code>	Binario (1/2)	Tiene acceso a internet.
042	<code>ind_tiene_moto</code>	Binario (1/2)	Tiene motocicleta.
043	<code>ind_tiene_tractor</code>	Binario (1/2)	Tiene tractor u otro vehículo agrícola.

Col	Nombre	Tipo	Descripción
044	<code>ind_tiene_carro</code>	Binario (1/2)	Tiene automóvil.
045	<code>ind_tiene_bien_raiz</code>	Binario (1/2)	Tiene un bien raíz distinto al que habita.
046–061	<code>ind_gasto_* / vlr_gasto_*</code>	Binario + Entero	Pares indicador-valor para ocho categorías de gasto: alimento, transporte, educación, salud, servicios públicos, celular, arriendo, otros. El indicador: 1=Sí, 2=No, 9=No aplica. El valor está en pesos colombianos.
062	<code>vlr_total_gastos</code>	Entero (pesos)	Suma total de todos los gastos del hogar.
063	<code>num_habita_vivienda</code>	Entero	Número de personas que habitan la vivienda.

Bloque 7: Eventos de riesgo (columnas 064–075)

Seis tipos de desastre natural. Cada uno tiene un par: indicador binario (1=Sí, 2=No) y conteo de eventos.

Cols	Nombres	Tipo	Evento
064–065	<code>ind/num_evento_inundacion</code>	Bin./Entero	Inundación.
066–067	<code>ind/num_evento_avalancha</code>	Bin./Entero	Avalancha o deslizamiento.
068–069	<code>ind/num_evento_terremoto</code>	Bin./Entero	Terremoto.
070–071	<code>ind/num_evento_incendio</code>	Bin./Entero	Incendio.
072–073	<code>ind/num_evento_vendaval</code>	Bin./Entero	Vendaval.
074–075	<code>ind/num_evento_hundimiento</code>	Bin./Entero	Hundimiento de terreno.

Bloque 8: Persona — características individuales (col. 076–129)

Col	Nombre	Tipo	Descripción
076	<code>num_personas_hogar</code>	Entero	Total de personas en el hogar. Clave para calcular hacinamiento.
077	<code>sexo_persona</code>	1–2 (cat.)	1=Hombre, 2=Mujer.
078	<code>tip_parentesco</code>	Entero	Parentesco con el jefe del hogar: 1=Jefe, 2=Cónyuge, 3=Hijo, 4=Nieto, 5=Padres, etc.
079	<code>tip_estado_civil</code>	1–6 (cat.)	Estado civil de la persona.

Col	Nombre	Tipo	Descripción
080	<code>ind_conyuge_vive_hogar</code>	Binario	El cónyuge vive en el hogar (9=No aplica).
081	<code>ide_conyuge</code>	Entero	Identificador de la persona cónyuge dentro del hogar.
082	<code>ind_padre_vive_hogar</code>	Binario	El padre vive en el hogar.
083	<code>ide_padre</code>	Entero	Identificador del padre dentro del hogar.
084	<code>ind_pariante_domestico</code>	Binario	Es pariente del empleado doméstico.
085	<code>ide_serv_domestico</code>	Entero	Identificador del empleado doméstico.
086-093	<code>ind_discap_*</code>	Binario (1/2)	Ocho indicadores de discapacidad, uno por dominio funcional: <code>ver</code> (visión), <code>oir</code> (audición), <code>hablar</code> (comunicación), <code>moverse</code> (movilidad), <code>banarse</code> (autocuidado), <code>salir</code> (desplazamiento), <code>entender</code> (cognición), <code>ninguna</code> (sin discapacidad). 1=Sí tiene, 2=No tiene.
094	<code>tip_seg_social</code>	0-9 (cat.)	Régimen de salud: 0=Ninguno, 1=Contributivo, 2=Especial, 3=Subsidiado, 9=No sabe.
095	<code>ind_enfermo_30</code>	Binario	Estuvo enfermo en los últimos 30 días.
096	<code>ind_acudio_salud</code>	Binario	Acudió a un servicio de salud (9=No aplica).
097	<code>ind_fue_atendido_salud</code>	Binario	Fue atendido (9=No aplica).
098	<code>ind_esta_embarazada</code>	Binario	Está embarazada (9=No aplica a hombres).
099	<code>ind_tuvo_hijos</code>	Binario	Tuvo hijos (9=No aplica).
100	<code>tip_cuidado_ninos</code>	Categorico	Tipo de cuidado a niños (9=No aplica).
101	<code>ind_recibe_comida</code>	Binario	Persona recibe comida fuera del hogar.
102	<code>ind_leer_escribir</code>	Binario	Sabe leer y escribir.
103	<code>ind_estudia</code>	Binario	Está matriculado y asistiendo actualmente.
104	<code>niv_educativo</code>	Entero (0-9)	Nivel educativo más alto alcanzado.

Col	Nombre	Tipo	Descripción
105	<code>grado_alcanzado</code>	Entero	Grado o año dentro del nivel educativo declarado.
106	<code>ind_fondo_pensiones</code>	Binario	Cotiza a un fondo de pensiones.
107	<code>tip_actividad_mes</code>	0–5 (cat.)	Actividad principal el mes anterior: 0=Trabajó, 1=Buscó empleo, 2=Estudió, 3=Oficio del hogar, 4=Pensionado, 5=Otra.
108	<code>num_sem_buscando</code>	Entero	Semanas buscando empleo (999=No aplica).
109	<code>tip_empleado</code>	Categorico	Tipo de relación laboral (99=No aplica).
110–129	<code>ind_ingr_* / vlr_ingr_*</code>	Bin.+Entero	Pares indicador-valor para ocho fuentes de ingreso: salario, honorarios, cosecha, pensión, remesa nacional, remesa exterior, arriendos, otros. Adicionalmente: <code>ind_ingr_estado</code> (subsidio del Estado), <code>vlr_ingr_fam_accion</code> (Familias en Acción), <code>vlr_ingr_col_mayor</code> (Colombia Mayor), <code>vlr_ingr_otro_subsidio</code> (otro subsidio).

Bloque 9: Indicadores IPM y score (columnas 130–145)

Estos son los indicadores pre-calculados por el DNP para medir la **Pobreza Multidimensional (IPM)**.

Col	Nombre	Definición (privación = 1)
130	<code>H_5</code>	Score de bienestar del hogar (compuesto, 0–10).
131	<code>I1</code>	Rezago escolar.
132	<code>I2</code>	Analfabetismo.
133	<code>I3</code>	Inasistencia escolar.
134	<code>I4</code>	Acceso a servicios para cuidado de la primera infancia.
135	<code>I5</code>	Trabajo infantil.
136	<code>I6</code>	Sin aseguramiento en salud.
137	<code>I7</code>	Barreras de acceso a servicios de salud.

Col	Nombre	Definición (privación = 1)
138	I8	Sin fuente de agua mejorada.
139	I9	Inadecuada eliminación de excretas.
140	I10	Pisos inadecuados.
141	I11	Paredes exteriores inadecuadas.
142	I12	Hacinamiento crítico.
143	I13	Sin cocina.
144	I14	Material de cocina inadecuado.
145	I15	Sin recolección de basuras.

Nota: I1–I15 son binarios (0=no hay privación, 1=hay privación), calculados directamente por el DNP con metodología oficial. Se usan directamente en el análisis de pobreza multidimensional sin transformación adicional.

Proceso ETL: de CSV a Parquet maestro

El proceso de transformación se desarrolló en tres versiones sucesivas, más un script complementario para la población DANE. Se documenta aquí cuál se usa para producción y qué hace cada uno.

Versión 1: ETL DuckDB inicial (`etl_sisben.py`)

Propósito: primera integración de los 6 CSV del DNP en un solo archivo Parquet.

Qué hace: lee todos los CSV del directorio fuente con DuckDB usando `read_csv_auto(..., union_by_name=True, all_varchar=True)` y los exporta directamente a Parquet con compresión ZSTD.

Virtud: velocidad (menos de 2 minutos) y manejo automático de columnas con nombres distintos entre años.

Limitación: todos los campos quedan como texto; no añade columna de año ni el grupo Sisbén.

CODEC: ZSTD (alta compresión, sin chunking).

Versión 2: ETL DuckDB con metadatos (`etl_sisben_v2.py`)

Propósito: añadir columnas de metadato extraídas del nombre del archivo.

Mejora: incorpora `año` (año del corte, extraído con regex del nombre del archivo) y `grupo_sisben` (primera letra de `Clasificacion`: A, B, C o D).

Limitación: el patrón regex original capturaba más de 4 dígitos en algunos nombres de archivo, generando años incorrectos.

Patch: corrección de regex (patch_parquet.py)

Propósito: corrección quirúrgica sin reejecutar todo el ETL.

Corrige la columna `anio` aplicando el patrón correcto: `(\d{4}).csv` que captura exactamente 4 dígitos antes de la extensión. Se aplicó solo sobre el Parquet existente, sin releer los CSV originales.

Versión 3 definitiva: Python chunk mode (etl_sisben_definitivo.py)

Este es el script de producción vigente. Tiene 450 líneas e implementa la lógica completa.

Flujo de procesamiento v3

1. Lee el Parquet generado por v2 como fuente (contiene los 6 CSV ya unidos con `anio` correcto).
2. Itera en lotes de **150.000 filas** usando `pq.ParquetFile.iter_batches()`.
3. Para cada lote: convierte a pandas → aplica 24 transformaciones → construye tabla PyArrow.
4. Escribe de forma incremental con `pq.ParquetWriter` usando compresión **Snappy**.
5. Al finalizar todos los lotes, reemplaza el archivo original.
6. Ejecuta verificación automática de tipos en una muestra de 50.000 filas.

Fragmento del núcleo del procesamiento:

```

1 CHUNK_ROWS = 150_000    # ~150 MB RAM por lote
2
3 pf = pq.ParquetFile(PARQUET_IN)
4 writer = None
5
6 for batch in pf.iter_batches(batch_size=CHUNK_ROWS):
7     df_chunk = batch.to_pandas()
8     df_chunk = calcular_columnas(df_chunk) # 24 transformaciones
9     table = pa.Table.from_pandas(df_chunk, preserve_index=False)
10    if writer is None:
11        writer = pq.ParquetWriter(PARQUET_OUT, table.schema,
12                                   compression="snappy")
13    writer.write_table(table)
14    del df_chunk, table, batch
15    gc.collect()          # Libera RAM del lote explícitamente

```

Script complementario: ETL de población DANE (etl_poblacion_cobertura.py)

Propósito: construir el denominador para la tasa de cobertura Sisbén.

Fuente: POB_ANT_2006-2035_Act08-2025-AjustMed.csv (proyecciones municipales del DANE para Antioquia).

Filtro: años 2021–2026.

Homologación: traduce los campos del DANE a la misma semántica del Sisbén: DPMP → `cod_mpio` (5 dígitos con `zfill`), “Hombres” → `sexo_persona=1`, “Mujeres” → `sexo_persona=2`, “Cabecera Municipal” → `Cod_clase=1`, “Centro Poblado y Rural Disperso” → `Cod_clase=3`. Los rangos de edad se construyen con la misma lógica quinquenal del Sisbén.

Resultado: `poblacion_proyectada.parquet` con 6 columnas: `cod_mpio`, `anio`, `Cod_clase`, `sexo_persona`, `Rango_Edad`, `Poblacion_Proyectada`.

Uso: se carga en Power BI como tabla auxiliar y se une al Sisbén para calcular:

$$\text{Cobertura} = \frac{\text{Personas en Sisbén}}{\text{Población DANE}} \times 100.$$

Las 24 columnas calculadas: lógica exacta

La función `calcular_columnas(df)` del script `etl_sisben_definitivo.py` aplica 24 transformaciones sobre cada chunk. A continuación se documenta cada una con su lógica exacta extraída del código.

Grupo A: Clasificación Sisbén

`orden_clasificacion` (Int64)

Fuente: `Clasificacion` (ej: “B4”, “A2”). **Lógica:** se extrae la primera letra y se mapea: A→1, B→2, C→3, D→4. Registros sin clasificación válida reciben valor 99.

```
1 grupo = df["Clasificacion"].astype(str).str[0]
2 df["orden_clasificacion"] = grupo.map(
3     {"A": 1, "B": 2, "C": 3, "D": 4}
4 ).fillna(99).astype("Int64")
```

Grupo B: Tipo y materiales de vivienda

`Tipo_Vivienda_txt` (String)

Convierte `tip_vivienda` (1–5) a texto descriptivo. Mapa: 1=Casa, 2=Apartamento, 3=Cuarto, 4=Otro, 5=Vivienda indígena.

`Material de las Paredes` (String)

Convierte `tip_mat_paredes` (0–7) a texto. Mapa: 0=Sin paredes, 1=Bloque/ladrillo/..., 2=Tapia pisada, 3=Bahareque, 4=Prefabricado, 5=Madera burda, 6=Guadua/caña, 7=Zinc/cartón/desechos.

Material del Piso (String)

Convierte `tip_mat_pisos` (1–6). Mapa: 1=Alfombra/mármol, 2=Baldosa, 3=Cemento, 4=Madera burda, 5=Tierra, 6=Otro.

Orden_Paredes (Int64)

Copia directa de `tip_mat_paredes` como entero limpio. Se usa para ordenar barras en visualizaciones.

Tipo_Ocupacion_txt (String)

Convierte `tip_ocupa_vivienda` (1–5). Mapa: 1=Arriendo, 2=Propia pagando, 3=Propia pagada, 4=Con permiso, 5=Posesión sin título.

Grupo C: Servicios públicos

Energia_txt / Acueducto_txt / Alcantarillado_txt / Gas_txt / Recoleccion_txt (String)

Las cinco columnas usan el mismo mapa binario aplicado a sus respectivos `ind_tiene_*`: 1→“Sí tiene servicio”, 2→“No tiene servicio”, otros→“Sin información”.

Clase_txt / Zona (String)

`Cod_clase` (1–3) mapeado a: 1→Urbano, 2→Urbano, 3→Rural. *Zona* es idéntica a *Clase_txt*; se mantienen dos nombres distintos por compatibilidad con visualizaciones previas.

Sanitario_txt (String)

Convierte `tip_sanitario` (1–5). Mapa: 1=Alcantarillado, 2=Pozo séptico, 3=Sin conexión, 4=Letrina/bajamar, 5=No tiene.

Grupo D: Calidad y hacinamiento de vivienda

Privaciones_Vivienda (Int64)

Suma de los 5 indicadores IPM de vivienda:

$$I11 + I12 + I13 + I14 + I15$$

Rango: 0 (sin privaciones) a 5 (máxima privación). Los NA se tratan como 0 en la suma.

Nivel_Calidad_Vivienda (String)

Clasificación a partir de `Privaciones_Vivienda`:

- 0 privaciones → “Sin privaciones”
- 1 o 2 privaciones → “Privación moderada”
- 3 o más privaciones → “Privación alta”

Personas_por_Cuarto (Float64)

Índice de hacinamiento:

$$\frac{\text{num_personas_hogar}}{\text{num_cuartos_vivienda}}$$

Cuando `num_cuartos_vivienda` = 0 se trata como NaN para evitar división por cero.

Cat_Hacinamiento (String)

`Personas_por_Cuarto` > 3 → “Hacinado”; de lo contrario → “No hacinado”. NaN → “Sin información”.

Grupo E: Persona y jefatura del hogar

Es_Jefe (Int64)

$$\text{tip_parentesco} = 1 \Rightarrow 1; \quad \text{otro} \Rightarrow 0$$

Sexo_Jefe (Int64)

Solo toma valor en la fila del jefe del hogar (`tip_parentesco`=1). En las demás filas del hogar queda como pd.NA. El valor es el mismo que `sexo_persona` de ese jefe.

Sexo_Jefe_Label (String)

Maapeo de `Sexo_Jefe`: 1→“Hombre jefe”, 2→“Mujer jefe”.

Grupo F: Edad

Rango_Edad (String)

17 rangos quinquenales con `numpy.select`: de “00-04” hasta “75-79” y “80+”. La condición se evalúa en cascada (≤ 4 , ≤ 9 , ..., ≤ 79 , ≥ 80).

Orden_Edad (Int64)

Maapea cada `Rango_Edad` a un entero del 1 al 17 para ordenar la pirámide poblacional: “00-04”=1, “05-09”=2, ..., “80+”=17.

Grupo G: Salud

Regimen_Salud_Limpio (String)

Convierte `tip_seg_social` (0–9): 0=Ninguno, 1=Contributivo, 2=Especial, 3=Subsidiado, 9=No sabe.

Normalización de tipos de datos

Todos los campos del CSV llegan como texto. El ETL aplica conversiones explícitas:

Conversión a Int64 (109 columnas)

Se usa `pd.to_numeric(series, errors="coerce").astype("Int64")` que maneja NaN nativamente (tipo anulable de pandas). Incluye: todos los indicadores binarios, identificadores, cantidades numéricas, valores de gasto/ingreso, edad, año, e indicadores IPM (I1–I15 y H_5).

Columnas que permanecen como String

`NOM_BARRIO`, `NOM_CORREGIMIENTO`, `NOM_VEREDA`, `Clasificacion`, `grupo_sisben`, `Fec_digitacion`, `marca`, `estado`, `filename`.

Normalización de cod_mpio

Se aplica: `str.replace(r'\.0$', '')` para eliminar el decimal que Python/pandas añade al leer enteros con NaN, seguido de `.str.zfill(5)` para garantizar 5 dígitos. Ej: “5001.0” → “05001”.

Normalización de nombres de columna

Tres columnas presentan inconsistencias de codificación entre archivos de distintos años: `ind_discap_bañarse`, `tip_cuidado_niños`, `Num_evento_vendaval`. El ETL detecta variantes y las renombra a la forma canónica mediante un mapeo automático.

Eficiencia lograda: comparativa cuantitativa

Métrica	Antes del ETL	Después del ETL
Apertura en Power BI Desktop	> 60 minutos	≈ 18 minutos
RAM pico durante carga	> 18 GB	≈ 4 GB
Evaluaciones DAX por apertura	600.000.000	0
Columnas calculadas en DAX	24 (en tiempo real)	0 (migradas al ETL)
Tamaño en disco	10+ GB (6 CSV texto)	< 3 GB (Parquet Snappy)
Tiempo de ejecución del ETL	60 min (carga CSV en PBI)	18 min (1 sola vez)
RAM pico durante ETL	N/A	< 2 GB (chunk mode)
Tipo de datos en fuente	Todo string	Correctos (Int64, Float64)
Número de archivos fuente	6 CSV independientes	1 Parquet maestro
Columnas finales	111 (DNP)	135 (111 + 24 calculadas)

¿Por qué 600 millones de evaluaciones?

Cada vez que Power BI Desktop abre el modelo, ejecutaba las 24 columnas DAX sobre las ≈ 25 millones de filas del Parquet fuente:

$$24 \times 25,000,000 = 600,000,000 \text{ evaluaciones por apertura}$$

Al mover esas 24 columnas al ETL (calculadas una sola vez en Python), el archivo Parquet que carga Power BI ya contiene los valores listos. VertiPq los comprime y no los recalcula.

¿Por qué Parquet con Snappy?

- **Formato columnar:** para analizar 1 columna, solo lee ese bloque. CSV lee todas las columnas de cada fila.
- **Compresión RLE:** columnas binarias como I1–I15 (solo 0 o 1) pasan de ≈ 200 MB a ≈ 3 MB por columna (ratio $\approx 66\times$).
- **Snappy vs ZSTD:** Snappy sacrifica algo de ratio por máxima velocidad de lectura, óptimo para Power BI que necesita leer rápido, no comprimir rápido.
- **Tipos nativos:** leer un `int64` nativo de Parquet es $5\times$ más rápido que convertir un string a número en Power BI.

Propuesta de transición a SQL

El Parquet maestro puede ser ingerido en una base de datos SQL (SQL Server, PostgreSQL) para habilitar actualizaciones automáticas y gobernanza de datos:

1. **DDL:** generar el esquema SQL directamente desde el schema del Parquet (tipos ya son correctos).
2. **Carga inicial:** `BULK INSERT` o `pandas.to_sql()` con `chunksize`.
3. **Partición:** tabla particionada por `año` para reemplazar solo el año nuevo en cada actualización.
4. **Gateway:** On-premises Data Gateway de Power BI en la red de la Gobernación para refresh programado.
5. **Refresh:** cuando el DNP entregue nuevo corte CSV, ejecutar el ETL y hacer `INSERT` solo del año nuevo.
6. **Auditoría:** tabla de log con fecha de ejecución, filas insertadas, hash del CSV fuente.

Glosario de términos clave

Clasificación

Clasificación Sisbén IV en formato “grupo + número” (ej: B4). El grupo (A–D) indica la vulnerabilidad; el número indica la posición ordinal dentro del grupo.

Parquet maestro

Archivo `sisben_master.parquet` que consolida los 6 cortes del DNP más las 24 columnas calculadas. Es la única fuente que Power BI carga.

Chunk mode

Técnica de procesamiento por lotes: en lugar de cargar 25M filas en RAM, el ETL procesa 150.000 filas a la vez liberando memoria entre lotes.

VertiPaq

Motor de compresión en columnas de Power BI. Comprime los datos del Parquet en RAM organizados por columna, permitiendo cálculos ultra-rápidos en DAX.

Indicadores IPM

I1–I15: 15 privaciones del Índice de Pobreza Multidimensional calculadas por el DNP. Valor 1 indica privación.

H_5

Score compuesto de bienestar del hogar. Rango 0–10.

tip_parentesco

Identifica el rol de la persona en el hogar. Valor 1 = jefe o jefa del hogar. Se usa para extraer atributos del jefe (**Es_Jefe**, **Sexo_Jefe**).